

# Identifikasi Citra Daun Menggunakan Morfologi, Local Binary Patterns dan Convex Hulls

Desta Sandya Prasvita

Program Studi Sistem Informasi, STIMIK ESQ  
Jl. TB Simatupang Kavling 1, Cilandak, Jakarta Selatan – 12560  
Email: desta.sandya@esqbs.ac.id

**Abstract:** This research proposes a leaf identification system with features fusion of leaf morphology, convex hulls (shape features) and  $LBP_{P,R}^{riu2}$  (texture features). Probabilistic Neural Network (PNN) is used as classifier. The experimental results of leaf identification system, average accuracy of combining all the features is 87.5%. Accuracy by combining three features higher than using morphological features (58.125%) or texture features (68.125%). In this research showed that the texture features more influence than morphological features for recognition of plants.

**Keywords:** Morphology, Local Binary Patterns, Convex Hulls, Probabilistic Neural Network

**Abstrak:** Penelitian ini mengusulkan sebuah sistem identifikasi daun dengan menggabungkan fitur morfologi daun, *convex hulls* (fitur bentuk) dan  $LBP_{P,R}^{riu2}$  (fitur tekstur). *Classifier* yang digunakan dalam penelitian ini adalah *probabilistic neural network* (PNN). Hasil eksperimen sistem identifikasi daun dengan menggabungkan ketiga fitur ini menunjukkan tingkat pengenalan dengan rata-rata akurasi sebesar 87,5%, akurasi dengan penggabungan ketiga fitur ini lebih tinggi jika dibandingkan dengan menggunakan fitur morfologi saja (58.125%) atau menggunakan fitur tekstur saja (68.125%). Pada penelitian ini juga memperlihatkan bahwa fitur tekstur merupakan fitur yang lebih mempengaruhi tingkat pengenalan tumbuhan dibandingkan dengan fitur morfologi.

**Kata Kunci:** Morfologi, Local Binary Patterns, Convex Hulls, Probabilistic Neural Network

## 1. PENDAHULUAN

Identifikasi tumbuhan tersebut perlu menggunakan herbarium atau *text book* untuk dibandingkan dengan objek aslinya, tapi prosesnya akan memakan waktu yang lama dan merepotkan. Tentunya herbarium juga memiliki kemungkinan rusak sehingga tumbuhan sulit untuk dikenali lagi. Saat ini, taksonomi tumbuhan biasanya mengadopsi metode klasifikasi tradisional. Banyak juga metode klasifikasi lain, seperti morfologi anatomi, biologi sel, biologi molekul, dan fitokimia juga telah digunakan [1].

Telah banyak penelitian-penelitian yang telah dikembangkan untuk identifikasi tumbuhan berbasis citra secara otomatis dengan menggunakan perangkat komputer.

Penelitian yang telah dilakukan sebelumnya untuk identifikasi citra daun menggunakan fitur morfologi dengan menggunakan *classifier* PNN akurasi rata-ratanya mencapai 90.3% [2]. Lee K.B. dan Kwang S.H. menggunakan ciri urat daun dan ciri bentuk dengan *fast fourier transform* dan *convex hulls* dengan akurasi mencapai 97.19% [3]. Kusmana melakukan penelitian untuk

identifikasi citra tumbuhan obat dilakukan penggabungan fitur *local binary patterns* dengan akurasi maksimal mencapai 86.667% [4]. Telah dilakukan juga untuk identifikasi tumbuhan obat, dengan penggabungan ketiga fitur ekstraksi citra (morfologi, tekstur, dan bentuk) dan menggunakan PNN sebagai metode klasifikasinya akurasi maksimumnya mencapai 74.67% [5].

Adapun tujuan penelitian ini, adalah peningkatan kinerja sistem pengenalan tumbuhan dengan menggabungkan fitur morfologi, tekstur menggunakan *Local Binary Patterns* (LBP) dan bentuk dengan *convex hulls*. Metode LBP yang digunakan pada penelitian ini adalah  $LBP_{P,R}^{riu2}$ , metode ini dianggap tahan terhadap rotasi dan bersifat *uniform*. Penelitian ini akan mengukur akurasi masing-masing fitur tanpa penggabungan dan juga mengukur akurasi penggabungan semua fitur.

## 2. LANDASAN TEORI

### 2.1. Local Binary Patterns (LBP)

*Local Binary Patterns* (LBP) pertama kali diusulkan oleh Ojala et al. pada tahun 2002 untuk klasifikasi tekstur yang bersifat *rotation invariant* [6]. Untuk mendapatkan nilai LBP dilakukan *thresholding* pada *pixel-pixel* tetangga yang berbentuk *circular* dengan menggunakan *pixel* pusat, kemudian mengalikannya dengan pembobotan biner. Sebagai contoh untuk *sampling points*  $P=8$  dan radius  $R=1$ , perhitungan nilai LBP diilustrasikan pada Gambar 1.

Threshold		bobot	
5	9	1	1
4	4	6	1
7	2	3	1

Gambar 1. Contoh Perhitungan Nilai LBP.

Secara matematis LBP dapat diformulasikan sebagai berikut:

$$LBP_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p$$

dimana,

$$s(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases}$$

dengan  $x_c$  dan  $y_c$  adalah koordinat *pixel* pusat,  $p$  adalah *circular sampling points*,  $P$  adalah jumlah *sampling points* atau *pixel* tetangga,  $g_p$  adalah nilai *gray scale* dari  $p$ ,  $g_c$  adalah *pixel* pusat, dan  $s$  atau *sign* adalah fungsi *threshold*. Untuk keperluan klasifikasi nilai-nilai LBP selanjutnya direpresentasikan dalam bentuk histogram [6].

### 2.2. Rotation Invariant Uniform Patterns ( $LBP_{P,R}^{riu2}$ )

*Rotation invariant uniform patterns* yang dinotasikan  $LBP_{P,R}^{riu2}$  merupakan operator yang tidak sensitif (*invariant*) terhadap perubahan rotasi dan bersifat *uniform*. Secara matematis *uniform patterns* dapat diekspresikan sebagai berikut:

$$U(LBP_{P,R}) = |s(g_{P-1} - g_c) - s(g_0 - g_c)| + \sum_{p=1}^{P-1} |s(g_p - g_c) - s(g_{p-1} - g_c)|$$

Nilai-nilai *uniform patterns* ditandai dengan nilai  $U(LBP_{P,R})$  yang kurang dari 2.  $LBP_{P,R}^{riu2}$  diformulasikan sebagai berikut:

$$LBP_{P,R}^{riu2} = \begin{cases} \sum_{p=0}^{P-1} s(g_p - g_c), & \text{if } U(LBP_{P,R}) \leq 2 \\ P + 1, & \text{selainnya} \end{cases}$$

Jika pola yang diidentifikasi termasuk *uniform patterns*, akan dihitung banyaknya bit satu pada pola tersebut yang menentukan letak *bin uniform patterns* berada. Jika  $P$  atau jumlah *sampling points* sama dengan delapan, nilai  $LBP_{P,R}^{riu2}$  ada dalam rentang nol sampai dengan sembilan. Pola-pola LBP yang tidak *uniform patterns* akan menjadi *bin* ke-9 [7].

### 2.3. Morfologi Daun

Ciri morfologi dibedakan menjadi dua, yaitu ciri dasar dan ciri turunan. Ciri dasar daun diantaranya diameter ( $D$ ), panjang fisik ( $L_p$ ), lebar fisik ( $W_p$ ), area ( $A$ ), dan perimeter ( $P$ ). Diameter merupakan titik terjauh di antara dua titik dari batas daun. Panjang fisik merupakan jarak dua titik pangkal daun. Lebar fisik dihitung berdasarkan panjang garis terpanjang yang memotong garis panjang fisik secara ortogonal. Area dihitung berdasarkan jumlah piksel yang berada di dalam tepi daun, sedangkan perimeter merupakan jumlah piksel yang berada pada tepi daun [2].

Dari lima ciri dasar tersebut, didapatkan tujuh ciri morfologi turunan. Nilai ciri turunan dapat dihitung dari rasio di antara ciri dasar daun. Ciri turunan daun ada tujuh yaitu [2]:

23. *Smooth factor*. Ciri untuk mengukur kehalusan suatu permukaan daun. Semakin halus suatu permukaan daun, maka nilainya semakin mendekati 1. Sebaliknya semakin kasar permukaan daunnya nilainya semakin mendekati 0.

24. *Aspect ratio* adalah rasio antara physiological length ( $L_p$ ) dan physiological width ( $W_p$ ).

$$\frac{L_p}{W_p}$$

25. *Form factor* digunakan untuk mendeskripsikan bentuk dari daun dan mengetahui seberapa bundar bentuk helai daun tersebut.

$$\frac{4\pi A}{P^2}$$

26. *Rectangularity* mendeskripsikan seberapa perseginya permukaan daun.

$$\frac{L_p W_p}{A}$$

27. *Narrow factor* adalah rasio antara diameter ( $D$ ) dan *physiological length*. Ciri ini untuk menentukan apakah bentuk helai daun tersebut tergolong simetri atau asimetri. Jika helai daun tersebut tergolong simetri, *narrow factor* bernilai 1. Jika asimetri, *narrow factor* bernilai lebih dari 1.

$$\frac{D}{L_p}$$

28. *Perimeter ratio of diameter*. Ciri ini untuk mengukur seberapa lonjong daun tersebut.

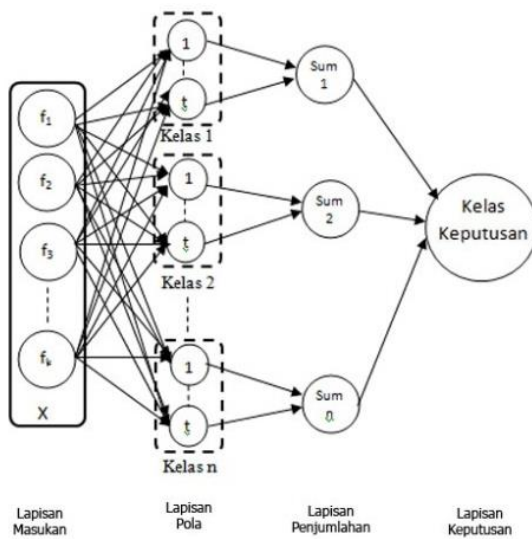
$$\frac{P}{D}$$

29. *Perimeter ratio of physiological length and physiological width*.

$$\frac{P}{(L_p + W_p)}$$

### 2.4. Probabilistic Neural Network (PNN)

*Probabilistic neural network* (PNN) merupakan *artificial neural network* (ANN) yang menggunakan teorema probabilitas klasik. PNN diperkenalkan oleh Donald Specht pada tahun 1990. PNN menggunakan pelatihan (*training*) *supervised*. PNN merupakan jaringan syaraf tiruan yang menggunakan *radial basis function* (RBF). RBF adalah fungsi yang berbentuk seperti bel yang menskalakan variabel nonlinear. Keuntungan utama menggunakan arsitektur PNN adalah *training* data PNN mudah dan cepat [2].



Gambar 2. Struktur PNN.

Struktur PNN terdiri atas empat lapisan, yaitu lapisan masukan, lapisan pola, lapisan penjumlahan, dan lapisan keputusan/keluaran. Struktur PNN ditunjukkan pada Gambar 2. Lapisan-lapisan yang menyusun PNN adalah sebagai berikut:

### 30. Lapisan input (input layer)

Lapisan masukan merupakan *input x* yang terdiri atas  $k$  nilai yang akan diklasifikasikan pada salah satu kelas dari  $n$  kelas.

### 31. Lapisan pola (pattern layer)

Pada lapisan pola dilakukan perhitungan jarak antara *input x* dengan vektor bobot  $x_{ij}$ , yaitu  $Z_i = x - x_{ij}$ , simbol minus menunjukkan jarak antara vektor.  $Z_i$  kemudian dibagi dengan bias tertentu  $\sigma$  dan selanjutnya dimasukkan ke dalam fungsi *radial basis*, yaitu  $radbas(n) = \exp -n^2$ . Dengan demikian, persamaan yang digunakan pada lapisan pola adalah sebagai berikut:

$$f(x) = \exp \left( - \frac{(x - x_{ij})^T (x - x_{ij})}{2\sigma^2} \right)$$

dengan  $x_{ij}$  menyatakan vektor bobot atau vektor latih kelas ke- $i$  urutan ke- $j$ .

### 32. Lapisan penjumlahan (summation layer)

Pada lapisan penjumlahan setiap pola pada masing-masing kelas dijumlahkan sehingga dihasilkan *probability density function* untuk setiap kelas. Persamaan yang digunakan pada lapisan ini adalah:

$$p(x) = \frac{1}{(2\pi)^{\frac{k}{2}} \sigma^k} \sum_{i=1}^t \exp \left( - \frac{(x - x_{ij})^T (x - x_{ij})}{2\sigma^2} \right)$$

### 33. Lapisan keluaran (output layer)

Pada lapisan keluaran *input x* akan diklasifikasikan ke kelas  $l$  jika nilai  $p_l(x)$  paling besar dibandingkan kelas lainnya.

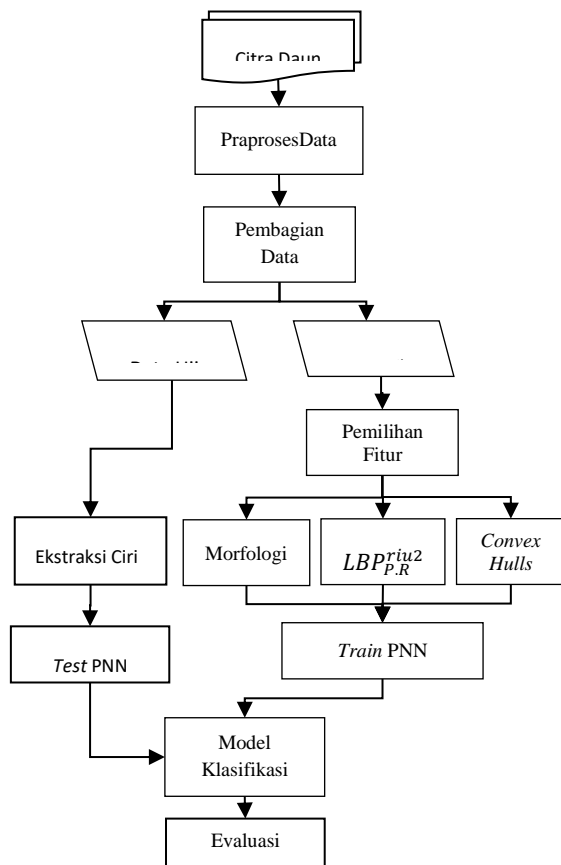
## 3. METODE

Penelitian ini mempunyai beberapa tahapan yaitu tahap pengumpulan data citra daun, praproses citra, pemilihan fitur, klasifikasi, dan evaluasi hasil penelitian. Tahapan proses tersebut diilustrasikan pada Gambar 3.

### 3.1. Citra Daun

Data diperoleh dari penelitian sebelumnya [2]. Total citra yang digunakan 1600 citra daun tumbuhan obat terdiri atas 32 jenis daun (masing-masing kelas 50 citra). Citra daun berformat JPEG dengan ukuran 640 x 480 *pixel*.

Pembagian data pada penelitian ini adalah untuk data *training* 80% dan data *testing* 20%. Data *training* digunakan untuk pemilihan fitur dan kemudian digunakan untuk membangun model klasifikasi. Sedangkan data uji digunakan untuk menguji model sistem klasifikasi.



Gambar 3. Metode Penelitian.

### 3.2. Praproses Fitur Citra

Sebelum masuk ke dalam tahap ekstraksi fitur, citra dilakukan praproses terlebih dahulu. Citra daun merupakan citra RGB dengan latar belakang putih. Masukan untuk ekstraksi morfologi dan bentuk adalah citra biner dengan *threshold* tertentu, sedangkan ekstraksi tekstur menggunakan citra *grayscale*.

### 3.3. Pemilihan Fitur

Identifikasi citra daun pada penelitian ini menggunakan 3 fitur yang dianggap baik berdasarkan penelitian-penelitian sebelumnya, yaitu ciri morfologi, tekstur, dan bentuk. Pada penelitian ini dilakukan beberapa percobaan untuk menentukan kombinasi fitur terbaik dalam pengenalan citra daun. Ketiga fitur tersebut akan dijelaskan pada bagian di bawah ini:

#### 34. Ekstraksi Ciri Morfologi

Ciri dasar yang digunakan pada penelitian ini adalah diameter, area, dan perimeter atau keliling daun. Dari ciri dasar dapat dikombinasikan sehingga mendapat delapan ciri turunan diantaranya *smooth factor*, *form factor*, rasio perimeter dan diameter, serta lima ciri urat daun. Informasi ciri ini direpresentasikan sebagai sebuah vektor dengan sebelas elemen.

#### 35. Ekstraksi Ciri Tekstur

Ekstraksi ciri tekstur pada penelitian ini menggunakan *local binary patterns* (LBP). LBP yang digunakan adalah  $LBP_{8,1}^{riu2}$  yang menghasilkan 10 vektor ciri.  $LBP_{8,1}^{riu2}$  ini dianggap tahan terhadap rotasi dan bersifat *uniform*.

#### 36. Ekstraksi Ciri Bentuk

Citra biner dari praproses yang telah dilakukan sebelumnya akan digunakan untuk ekstraksi bentuk dengan menggunakan *convex hulls*. Ciri ini didapatkan dari selisih antara area citra hasil *convex hulls* dengan area citra asli daun (Lee, K.B. dan Kwang S.H. 62).

Gambar 4. (a) Citra Biner, (b) Citra Biner Hasil *Convex Hulls*.

### 3.4. Klasifikasi dengan Probabilistic Neural Network

Lapisan output memiliki 32 target kelas sesuai dengan jumlah jenis daun. Untuk lapisan pola hanya digunakan satu model PNN yaitu dengan nilai bias ( $\sigma$ ) tertentu. Sedangkan lapisan masukan untuk klasifikasi PNN diambil dari citra daun yang telah melewati tahap ekstraksi sebelumnya. Ada 4 percobaan untuk lapisan masukan pada penelitian ini. Di bawah ini adalah 4

percobaan yang dilakukan untuk lapisan masukan pada model PNN.

Tabel 1. Kombinasi Percobaan Input pada Model PNN

Percobaan	Kombinasi Input
I	11 fitur morfologi.
II	10 fitur tekstur dengan $LBP_{8,1}^{riu2}$ .
III	Penggabungan fitur morfologi dan fitur tekstur ( $LBP_{8,1}^{riu2}$ ), sehingga menghasilkan 21 vektor ciri.
IV	Penggabungan 11 fitur morfologi, 10 fitur tekstur ( $LBP_{8,1}^{riu2}$ ), dan 1 fitur bentuk dengan <i>convex hulls</i> , sehingga menghasilkan 22 vektor ciri.

### 3.5. Evaluasi Hasil

Tahapan akhir pada penelitian ini adalah menghitung akurasi sistem identifikasi daun yang dibuat ini. Hasil penelitian ini diukur dengan menggunakan tingkat akurasi dari data citra yang diuji dan diamati. Akurasi terhadap kinerja model klasifikasi PNN dapat dihitung pada formulasi berikut :

$$\text{Akurasi} = \frac{\sum \text{data uji benar diklasifikasi}}{\sum \text{data uji}} \times 100\%$$

## 4. HASIL DAN PEMBAHASAN

Total data yang digunakan dalam penelitian ini adalah sebanyak 1600 citra daun. Pembagian data pada penelitian ini dilakukan dengan membagi data latih dan data uji masing-masing untuk data latih sebanyak 80% dan data uji 20%. Terdapat 32 kelas dan setiap kelas memiliki 50 citra daun, sehingga sebanyak 40 citra digunakan untuk pelatihan dan 10 citra yang diujikan dari setiap kelasnya.


Ekstraksi fitur pada citra daun hanya dilakukan pada *pixel-pixel* yang menyusun daun. Latar belakang yang berwarna putih tidak dimasukkan dalam proses ekstraksi agar tidak menjadi penciri. Ekstraksi fitur tekstur pada penelitian ini menggunakan tiga buah *descriptor*, yaitu morfologi,  $LBP_{P,R}^{riu2}$  dan *convex hulls*. Citra dikonversi ke model *warna*

*gray scale* dan dilakukan binerisasi sebelum dilakukan proses ekstraksi. Penggabungan fitur tersebut dilakukan dengan mengekstraksi masing citra, kemudian dari masing-masing fitur yang dihasilkan dirangkai menjadi satu histogram (*concatenation*).

Pada Penelitian ini dilakukan 4 buah percobaan, yaitu percobaan pertama menggunakan fitur morfologi sebagai inputan, percobaan kedua menggunakan fitur  $LBP_{P,R}^{riu2}$ , percobaan ketiga menggabungkan fitur morfologi dan fitur  $LBP_{P,R}^{riu2}$ , dan percobaan terakhir menggabungkan 3 buah fitur (morfologi,  $LBP_{P,R}^{riu2}$ , dan *convex hulls*).

### 4.1. Hasil Percobaan 1 (11 fitur morfologi)





Percobaan pertama adalah menggunakan 11 fitur morfologi. Menggunakan bias ( $\sigma$ ) sebesar 0.0001 yang digunakan sebagai parameter penentu dalam klasifikasi PNN. Pada percobaan ini menghasilkan akurasi sebesar 58.125%. Di bawah ini adalah grafik akurasi setiap kelas pada percobaan pertama.



Gambar 5. Grafik Akurasi untuk Setiap Kelas Menggunakan Fitur Morfologi.

Kelas 13 dan 14 (*Chimonanthus praecox* L dan *Ligustrum lucidum* Ait. f) adalah kelas yang paling sedikit terklasifikasi dengan baik dalam pengenalan menggunakan fitur morfologi. Hal ini disebabkan oleh kemiripan nilai fitur morfologi di antara kedua jenis daun tersebut terhadap kelas lain. Di bawah ini adalah tampilan visual dari kelas 13 (*Chimonanthus*

*praecox* L) yang salah teridentifikasi sebagai *Ligustrum lucidum* Ait. f, dan kelas 14 (*Ligustrum lucidum* Ait. f) yang salah teridentifikasi sebagai *Aesculus chinensis* dapat dilihat pada Gambar 6.

<p>Kelas 13 (<i>Chimonanthus praecox</i> L)</p> 	<p>Salah teridentifikasi sebagai <i>Ligustrum lucidum</i> Ait. F</p> 
<p>Kelas 14 (<i>Ligustrum lucidum</i> Ait. f)</p> 	<p>Salah teridentifikasi sebagai <i>Aesculus chinensis</i></p> 


Gambar 6. Contoh Data Uji yang Salah Teridentifikasi pada Fitur Morfologi.

#### 4.2. Hasil Percobaan 2 (10 fitur $LBP_{P,R}^{riu2}$ )





Percobaan kedua adalah menggunakan 10 fitur  $LBP_{P,R}^{riu2}$  dengan operator 8,1. Menggunakan bias ( $\sigma$ ) sebesar 0.002 yang digunakan sebagai parameter penentu dalam klasifikasi PNN. Pada percobaan ini menghasilkan akurasi sebesar 68.125%. akurasi pada percobaan kedua ini lebih tinggi dibandingkan dengan akurasi pertama. Hal ini membuktikan bahwa fitur tekstur menggunakan  $LBP_{P,R}^{riu2}$  ini cukup baik bila dibandingkan fitur morfologi. Gambar 7 adalah grafik akurasi setiap kelas pada percobaan kedua.

Akurasi terkecil pada pengenalan citra daun menggunakan fitur tekstur dengan  $LBP_{P,R}^{riu2}$  adalah pada kelas 26 (*Manglietia fordiana* Oliv) dan kelas 27 (*Acer buergerianum* Miq). Terdapat kesamaan nilai fitur tekstur di antara kedua jenis daun

tersebut terhadap kelas lain. Di bawah ini adalah tampilan visual dari kelas 26 (*Manglietia fordiana* Oliv) yang diidentifikasi sebagai *Nerium oleander* L, dan kelas 27 (*Acer buergerianum* Miq) yang diidentifikasi sebagai *Acer Palmatum* dapat dilihat pada Gambar 8.



Gambar 7. Grafik Akurasi untuk Setiap Kelas Menggunakan Fitur  $LBP_{P,R}^{riu2}$ .


<p>Kelas 26 (<i>Manglietia fordiana</i> Oliv)</p> 	<p>Salah teridentifikasi sebagai <i>Nerium oleander</i> L</p> 
<p>Kelas 27 (<i>Acer buergerianum</i> Miq)</p> 	<p>Salah teridentifikasi sebagai <i>Acer Palmatum</i></p> 

Gambar 8. Contoh Data Uji yang Salah Teridentifikasi pada Fitur  $LBP_{P,R}^{riu2}$ .



#### 4.3. Hasil Percobaan 3 (21 fitur morfologi dan fitur $LBP_{P,R}^{riu2}$ )


Pada percobaan ketiga dilakukan dengan menggunakan 21 fitur gabungan antara 11 fitur morfologi dan 10  $LBP_{P,R}^{riu2}$  dengan operator 8,1 dengan bias ( $\sigma$ ) PNN yang digunakan sebesar 0.003. Pada percobaan ini menghasilkan akurasi sebesar 80.99%. Akurasi pada percobaan ketiga ini lebih tinggi dibandingkan dengan akurasi pertama dengan fitur morfologi saja dan percobaan kedua dengan fitur tekstur ( $LBP_{P,R}^{riu2}$ ) saja. Hal ini memperlihatkan bahwa menggabungkan fitur morfologi dan tekstur menggunakan  $LBP_{P,R}^{riu2}$  ini dapat meningkatkan akurasi. Di bawah ini adalah grafik akurasi setiap kelas pada percobaan ketiga.



Gambar 9. Grafik Akurasi untuk Setiap Kelas Menggunakan Penggabungan Fitur Morfologi dan Fitur  $LBP_{P,R}^{riu2}$ .

#### 4.4. Hasil Percobaan 4 (22 fitur morfologi, fitur $LBP_{P,R}^{riu2}$ , dan *convex hulls*)


Pada percobaan keempat menggunakan 22 fitur gabungan antara 11 fitur morfologi, 10  $LBP_{P,R}^{riu2}$ , dan satu fitur *convex hulls* dengan bias ( $\sigma$ ) PNN yang digunakan sebesar 0.0065. Pada percobaan ini menghasilkan akurasi sebesar 87.5%. Penggabungan fitur morfologi, tekstur menggunakan  $LBP_{P,R}^{riu2}$  dan bentuk menggunakan *convex hulls* ini dapat meningkatkan akurasi. Gambar 10 adalah grafik akurasi setiap kelas pada percobaan 4.



Gambar 10. Grafik Akurasi untuk Setiap Kelas Menggunakan penggabungan Fitur Morfologi, Fitur  $LBP_{P,R}^{riu2}$  dan *Convex Hulls*

#### 4.5. Perbandingan Percobaan

Dari hasil keempat percobaan, pada percobaan keempat memperlihatkan bahwa penggabungan fitur morfologi, tektur, dan bentuk memiliki akurasi tertinggi yaitu sebesar 87.5%. Hal ini membuktikan bahwa ketiga fitur ini dapat saling melengkapi satu sama lain dan dapat meningkatkan akurasi pengenalan daun. Pada percobaan kedua memperlihatkan bahwa fitur tekstur lebih tinggi akurasinya dibanding fitur morfologi, hal ini terlihat bahwa fitur tekstur lebih mempengaruhi bila dibandingkan fitur morfologi. Pada percobaan ketiga dan keempat membuktikan bahwa penambahan 1 fitur bentuk dengan *convex hulls* juga berpengaruh terhadap peningkatan akurasi pengenalan citra daun.



Gambar 11. Perbandingan Akurasi Klasifikasi Setiap Percobaan.



## 5. PENUTUP

### 5.1. Kesimpulan

Pada penelitian ini memperlihatkan bahwa tingkat pengenalan pada sistem pengenalan daun yang diusulkan ini masih belum meningkatkan akurasi terhadap penelitian-penelitian yang telah dilakukan sebelumnya. Tapi berdasarkan hasil dari eksperimen penelitian identifikasi citra daun ini dapat ditarik beberapa kesimpulan sebagai berikut:

Fitur tekstur menggunakan  $LBP_{P,R}^{riu2}$  lebih mempengaruhi tingkat pengenalan tumbuhan dibandingkan dengan fitur morfologi. Terlihat akurasi menggunakan fitur tekstur sebesar 68.125%, sedangkan akurasi menggunakan fitur morfologi sebesar 58.125%.

37. Sistem identifikasi daun dengan menggabungkan ketiga fitur ini menunjukkan tingkat pengenalan dengan rata-rata akurasi sebesar 87,5%, akurasi dengan penggabungan ini lebih tinggi jika dibandingkan dengan menggunakan fitur morfologi saja (58.125%) atau menggunakan fitur tekstur saja (68.125%).

38. Fitur bentuk dengan *convex hulls* juga dapat meningkatkan akurasi. Hal ini terlihat penggabungan antara fitur morfologi dan  $LBP_{P,R}^{riu2}$  menghasilkan akurasi sebesar 80.99%. Sedangkan penggabungan ketiga fitur (morfologi,  $LBP_{P,R}^{riu2}$  dan *convex hulls*) memiliki akurasi sebesar 87.5%.

### 5.2. Saran

Penelitian ini masih mempunyai beberapa kekurangan yang dapat diperbaiki pada penelitian selanjutnya. Adapun beberapa saran untuk penelitian selanjutnya sebagai berikut:

1 Melakukan percobaan terhadap ekstraksi fitur lain seperti menggunakan *fast fourier transform*, *color moments*, dan

filter gabor agar dapat meningkatkan akurasi untuk identifikasi citra daun.

2 Melakukan perbandingan tingkat akurasi dengan *classifier* yang lain, seperti jaringan syaraf tiruan propagasi balik dan *support vector machine* (SVM).

### DAFTAR PUSTAKA

- [1] Du, Ji-Xiang., Xiao-Feng Wang. dan Guo-Jun Zhang. "Leaf shape based plant species recognition". Applied Mathematics and Computation (2007): 883-893.
- [2] Wu, S.G. "A Leaf Recognition Algorithm for Plant Classification Using Probabilistic Neural Network". The 7th IEEE International Symposium on Signal Processing and Information Technology (2007): 1-6.
- [3] Lee, Kue-Bum., and Kwang-Seok Hong. "An Implementation of Leaf Recognition System using Leaf Vein and Shape". International Journal of Bio-Science and Bio-Technology 5. 2 (2013): 57-66.
- [4] Kusmana, I. "Penggabungan Fitur Local Binary Patterns untuk Identifikasi Citra Tumbuhan Obat". skripsi. Bogor: Fakultas Matematika dan Ilmu Pengetahuan Alam, Institut Pertanian Bogor. 2011.
- [5] Herdiyeni, Yeni et al. "A Computer Aided System for Tropical Leaf Medicinal Plant Identification". International Journal Advanced Science Engineering Information Technology 3.1 (2013): 23-27.
- [6] Ojala, T et al. "Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns". IEEE Transactions On Pattern Analysis And Machine Intelligence 24.7 (2002): 971-986.
- [7] Mäenpää, Topi. "The Local Binary Pattern Approach To Texture Analysis – Extensions And Applications". Infotech

Oulu and Department of Electrical and Information Engineering, University of Oulu. 2003.